BELA：分层预算下覆盖保真约束的查询自适应视觉 Token 剪枝

Anonymous CVPR submission

Abstract

大型视觉语言模型把图像编码成很长的视觉 *token* 序列，预填充计算和键值缓存都随这个前缀增长。现有剪枝留下三类没有被分开处理的缺口：单一深度的显著性不反映中层与深层排序的变化，纯视觉覆盖不优先保留当前问题需要的局部线索，语言模型之前一次定死的容量又让浅层交互和深层冗余共用同一个长度。本文将剪枝写成给定分层计算预算下、覆盖保真约束的查询自适应子集选择：在固定容量的视觉代表基底附近提高问题相关性，同时约束总体覆盖失真和集合修改范围。免训练框架 *BELA* 用双深度信息建立基底，以格子配额限制补选集中，再做有限次同容量交换，最后按层执行。局部交换保持容量、修改范围和覆盖包络，不声称求得全局最优。在 *LLaVA-1.5-7B* 上，层均视觉容量为原始网格的 1/18、视觉 *token-layer* 预算减少 *94.4%* 的已完成配置中，六项相对平均为 *95.66%*。其余预算、*AI2D*、*VizWiz*、跨模型和视频格子仍待同协议填入。该比值不是单题正确率，预算比例也不是实测加速。

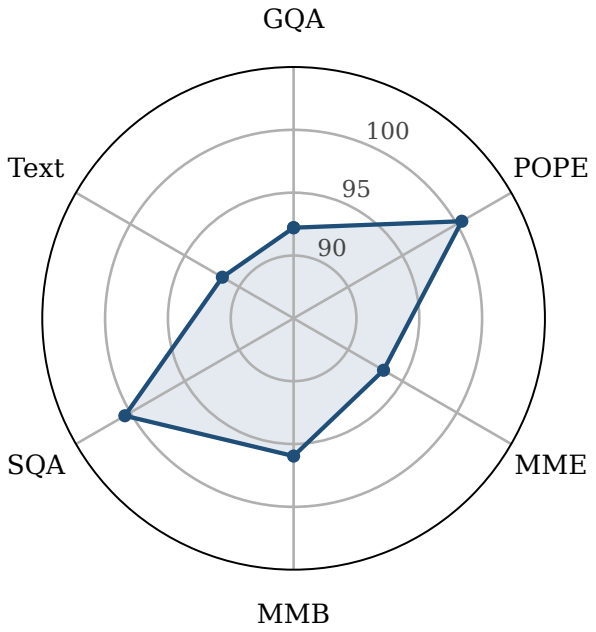


Figure 1. 已完成配置的六项相对分数。径向轴是成绩除以固定参考，从 85 起绘，100 表示与完整模型持平。MME 使用感知分。TextVQA 低于其余五项。

1. 引言

Flamingo、BLIP-2 和 LLaVA 把视觉编码器接到语言模型上，随后的高分辨率与视频模型继续增加视觉位置 [1, 3, 18, 19, 22–24]。LLaVA-1.5 的常用网格有 576 个视觉 token，往往长于问题本身。长度为 n、宽度为 d 的自注意力含有随 n^2d 增长的配对项，前馈层和 KV cache 也随前缀变长 [17, 31]。压缩冗余视觉位置，是算子优化之外的一条途径 [5, 36, 40]。

已有方法按三条线选择保留谁，每条线都留下一个原理缺口。第一，显著性排序通常只读一个深度。中层和深层的高分位置并不重合：1,024 张图上，两套前排的 Jaccard 均值是 0.331。只用其中一层，入口会丢掉另一层才排到前面的位置。第二，多样性或覆盖回答的是图像内部谁能代表其余位置。DivPrune、DART 和 SCoRe 的代表关系不读取当前问题，同一幅图因此得到同一个入口 [2, 32, 35]。第三，VisionZip、CoIn 和 PruneSID 主要在语言模型之前做成一条紧凑序列，后层容量被入口长度固定 [7, 8, 36]。入口过少时，浅层还没有足够的交互计算；走到深层以后，多留的视觉位置对平均分数的推动变小。PyramidDrop、SparseVLM 和 ViTCoP 已经按层缩短序列 [28, 34, 40]。在相同的层均预算下，保留数怎样沿深度分配，仍然决定实际能到达的性能。

这三件事不能收成一次无约束排序。SCoRe 把显著性与覆盖写成加权 k-center，CoIn 在信息性和覆盖的共同引导下一次选出子集 [7, 35]。二者都一次决定最终集合。本文要分开的是：基底先固定，问题只能在多大范围内改它，后层又按什么容量执行。

给定非增的层容量和与问题无关的基底 S_0，入口适配在容量不变、相对 S_0 的覆盖失真增量不超过 δ、交换距离不超过 B 的集合里，提高问题效用。这个可行域记为 $\mathcal{F}(S_0)$。BELA 不求解该域上的全局最优。它用双深度描述和格子配额生成 S_0，再从 S_0 做有限次一进一出的交换；接受的交换留在覆盖包络内。同一组原始索引随后按层日程嵌套收缩。选择描述只决定索引，送入语言模型的仍是原模型深层行，参数也不更新。

在 LLaVA-1.5-7B 的已完成极限预算上，六项相对平均为 95.66%，见图 1。格子配额基底是 93.89%，最小一档问题交换把它提高到 95.66%，GQA 净增 145 题，TextVQA-OCR 同时下降。表 1 为 77.8%、88.9% 和 94.4% 三档预留了同协议对照；目前只有 94.4% 的 BELA 一行有记录。

本文的贡献有三点。第一，把入口修改写成分层预算下、带覆盖失真和修改范围约束的查询自适应子集选择。第二，给出一个免训练实例：双深度描述补上单层排序，格子配额补上补选集中，有界交换补上“加入收益不能自动批准移除”，分层日程把浅层参与和深层保留分开。第三，报告这一实例在六项任务上的取舍、交换范围和层预算分配，并把尚未测量的格子留空。

2. 相关工作

单一深度的显著性。 FastV 用语言模型浅层注意力做一次剪枝，SparseVLM 用文本评分者调节视觉位置，VisionZip 和 VisPruner 在视觉特征上区分重要性并去重 [5, 36, 38, 40]。这些分数来自一个深度或一次交互。HiPrune 比较了视觉深度上的注意力 [25]，但高分集合是否随深度改换，需要直接看两套前排的重合。本文用对齐的中层与深层显著性做这件事。重合较低时，单层前排不能代替另一层的排序。送入语言模型的仍是深层原始行，拼接描述只参与选择。

不读问题的覆盖。 ToMe 合并相近 token，DART 用重复关系对照重要性排序，DivPrune 把保留集合写成最大最小多样性问题 [2, 4, 32]。SCoRe 把显著性加权的代表覆盖收成一次 k-center [35]。这些构造改善的是图像内部的代表关系。换一个问题，入口可以保持不变。CDPruner、MMTok、CoIn 和 QCPruner 把指令、文本对象或查询效用写进同一次集合目标 [6, 7, 14, 39]。问题信号因此参与了选择，但“谁该加入”和“谁可以被换掉”仍是同一个目标的两侧，也没有先固定一个与问题无关的基底。BELA 把覆盖留在约束里：基底先产生，问题效用只在失真上界和交换距离内上升。初始化并不最大化后一步的覆盖，所以这步交换不能套用次模贪心的近似界 [21]。

入口一次定长。 PruneSID、VisionZip、LLaVA-PruMerge 和 CoIn 主要在语言模型之前得到紧凑序列，后层看见的视觉长度等于入口 [7, 8, 29, 36]。入口若被压得过低，浅层缺少交互计算；深层若继续维持入口长度，多出来的位置不一定再提高平均分数。PyramidDrop 把保留数排成逐段日程，ViTCoP 把视觉端筛选和深层精剪分成阶段，STAR-Pro 把覆盖池和嵌套精炼放在同一个层均预算下 [12, 28, 34]。BELA 沿用嵌套收缩，但不把某一种保留个数写成方法定义。实验在相同的视觉 token-layer 总和下比较第一次收缩的早晚，以及末段多留几个位置的差别。视频上的 FrameFusion 也是先合并再按重要性缩短 [11]，它处理的是帧间重复，不是本文的图像入口适配。

3. 方法

3.1. 预算与问题

视觉编码器给出 N 个与原始 patch 对齐的位置，索引域为 $\mathcal{V}$。解码器有 L 层。第 ℓ 层实际处理的视觉集合为 A_ℓ，容量日程 $\mathrm{K} = (K_\ell)$ 满足

$$A_{\ell+1} \subseteq A_\ell, \qquad |A_\ell| = K_\ell. \tag{1}$$

层预算和层均容量是 $W(\mathrm{K}) = \sum_{\ell=1}^{L} K_\ell$ 与 $\bar{K} = W/L$。W 只累计各层看见的视觉位置，不是 FLOPs、延迟或显存。入口没有进入 A_1 的位置，不能被后层排序直接选回。

设与问题无关的基底为 S_0、$|S_0| = K$，问题效用为 U_Q，覆盖失真为 D_G。交换距离 $d_{\mathrm{ex}}(S, S_0) = |S \setminus S_0|$。记 $\Delta D_G(S) = D_G(S) - D_G(S_0)$。可行域要求容量仍为 K，失真增量不超过 δ，距离不超过 B：

$$\mathcal{F}(S_0) = \{S : |S| = K,\ d_{\mathrm{ex}}(S, S_0) \le B,\ \Delta D_G(S) \le \delta\}. \tag{2}$$

入口适配选择

$$S_Q \in \arg\max_{S \in \mathcal{F}(S_0)} \big[U_Q(S) - U_Q(S_0)\big]. \tag{3}$$

式 (3) 规定方向、代价和范围。算法从 S_0 做局部交换，不求解这个全局最优，也不继承次模近似界。各模型和各预算的具体 K_ℓ 只出现在实验配置里。

3.2. 双深度描述与格子配额

记中层、深层特征为 $x_i^{\mathrm{m}}, x_i^{\mathrm{d}}$，配套显著性 $s_i^{\mathrm{m}}, s_i^{\mathrm{d}}$。显著性是 CLS 到 patch 的注意力按头求和。$\hat{x}$ 表示逐位置 ℓ_2 归一化。深度权重 $\beta \in (0, 1)$ 同时用于拼接和分数：

$$m_i = \big[\sqrt{1-\beta}\,\hat{x}_i^{\mathrm{d}};\ \sqrt{\beta}\,\hat{x}_i^{\mathrm{m}}\big], \tag{4}$$

$$s_i = (1-\beta)\, s_i^{\mathrm{d}} + \beta\, s_i^{\mathrm{m}}. \tag{5}$$

$\beta = 0$ 退回深层，$\beta = 1$ 退回中层。m_i 只用于比较位置。送入投影器和语言模型的，是被选中索引上的深层原始行。

$G \times G$ 的网格划成 $C \times C$ 个格子，

$$g(r, c) = \lfloor r/(G/C) \rfloor C + \lfloor c/(G/C) \rfloor. \tag{6}$$

锚点 $\mathcal{A}$ 是显著性最高的 $K - b$ 个位置。格子原型 p_g 是该格锚点描述之和再归一化；空格原型为 0。残差池 $\mathcal{P}$ 是原显著性前 K 名之外的位置，不是锚点之外的全部位置。效用为

$$u_i = s_i\big(1 - \mathrm{clamp}(\cos(m_i, p_{g(i)}), 0, 1)\big). \tag{7}$$

余弦不大于 0、或格子里还没有锚点的残差，不进入这轮排序。然后按格计数：每一格先最多取 τ 个，不够就把 τ 提高，直到取满 b 个。仍不够时按显著性回补，已有锚点的格子优先。记这个带上限的选择为 TopK_b^{τ}，

$$S_0 = \mathcal{A} \cup \mathrm{TopK}_b^{\tau}(u; \mathcal{P}_+). \tag{8}$$

旧覆盖是在同一效用上直接取前 b 名。格子上限是二者仅有的算法差别，不是另一套覆盖目标。空格原型会使新颖项饱和，因此要先排除无锚点或非正余弦的候选。

3.3. 覆盖保真下的同容量交换

交换保持 $|S| = K$，次数不超过预算 B。B 不是问题里的词数。查询只用问题句里的内容词：选项、答题说明和 OCR 行留在语言模型输入中，不进入这个方向。内容词嵌入的均值记为 $\bar{t}$，投影后的视觉位置记为 v_i。

$$a_i = \cos\big(\mathrm{normalize}(v_i), \mathrm{normalize}(\bar{t})\big), \tag{9}$$

$$q_i = \sigma\Big(\mathrm{clamp}\big((a_i - \mathrm{med}(a))/(2\,\mathrm{std}(a)), -8, 8\big)\Big). \tag{10}$$

$U_Q(S) = \sum_{i\in S} q_i$。空内容或尺度过小则跳过交换。补丁相似度是选择描述的余弦截断到 $[0,1]$，多视图时取平均，记为 G_{ij}。全体位置的最近代表覆盖和失真是

$$C_G(S) = N^{-1}\sum_{i\in\mathcal{V}} \max_{j\in S} G_{ij}, \qquad D_G(S) = 1 - C_G(S). \tag{11}$$

换出与换入优先级分别为

$$\pi_i^{\mathrm{drop}} = (1 - q_i) + \lambda_r \max_{j\in S\setminus\{i\}} G_{ij}, \tag{12}$$

$$\pi_i^{\mathrm{donor}} = q_i\big(1 - \max_{j\in S} G_{ij}\big). \tag{13}$$

两侧各留一个固定大小的候选池。对换出 u 和换入 v，令 $S' = S \setminus \{u\} \cup \{v\}$，$\Delta q = q_v - q_u$，$\nu(v \mid S) = 1 - \max_{j\in S} G_{vj}$，$\Delta C_G = C_G(S') - C_G(S)$。三个门是 $\Delta q \ge \gamma$、$\nu \ge \eta$、$\Delta C_G \ge -\varepsilon$。通过的候选里取

$$(u^\star, v^\star) \in \arg\max \big[\Delta q\, \nu(v \mid S) + \lambda_c \Delta C_G\big]. \tag{14}$$

没有一对通过门就停止。接受后重造候选，达到 B 步也停止。设 $R = S \setminus \{u\}$，$b_i(R) = \max_{j\in R} G_{ij}$，空集取 0。移除损失和加入补偿是

$$L_G = N^{-1}\sum_i [G_{iu} - b_i(R)]_+, \quad A_G = N^{-1}\sum_i [G_{iv} - b_i(R)]_+ \tag{15}$$

于是 $\Delta C_G = A_G - L_G$。覆盖门要求新代表至少补上旧代表超出容忍量的损失。接受 $T \le B$ 次后，容量仍为 K，修改距离至多为 T，并且

$$C_G(S_Q) \ge C_G(S_0) - T\varepsilon, \qquad U_Q(S_Q) \ge U_Q(S_0) + T\gamma. \tag{16}$$

取 $\delta = B\varepsilon$，这是式 (2) 的一条覆盖可行性包络。它约束的是特征代理，不是答案正确性。

3.4. 分层执行

S_Q 的深层原始行与完整文本一起进入解码器。在剪点上，用该层已经算好的问题行 query 和视觉 key，不改主注意力。先在完整合法前缀上做 softmax，取出当前视觉列后再按行归一化，得到 $P_{t,i}$。权重 w_t 正比于问题词 t 落在视觉列上的质量，

$$r_i = \sum_t w_t P_{t,i}. \tag{17}$$

r 再归一化。后一次剪点按 r 取前排，并保持式 (1)。第一次剪点在当前候选集上比较现在的秩和按原始 patch 编号对齐的早期秩。π 表示归一化秩，

$$\rho_i = \omega\,\pi(r_i^{\mathrm{now}}) + (1-\omega)\big[\pi(r_i^{\mathrm{now}}) - \pi(r_i^{\mathrm{old}})\big]. \tag{18}$$

第一次按 ρ 取前排，以后按 r。被删位置的 RoPE 编号保持原始编号。各层缓存保留该层实际看见的长度，因此浅层已经形成的表示仍可能影响后面的生成。日程的具体保留数不进入上述定义。

4. 实验

4.1. 实验设置

主实验使用 LLaVA-1.5-7B [23]。高分辨率迁移预留 LLaVA-NeXT-7B 和 Qwen2.5-VL-7B，视频骨干与 LLaVA-OneVision-7B 的位置另表保留 [3, 18, 24]。对比按依据分成三组，每组三种。交互注意力：FastV、SparseVLM、ViTCoP [5, 28, 40]。视觉代表：DART、DivPrune、SCoRe [2, 32, 35]。联合选择：VisionZip、CoIn、PruneSID [7, 8, 36]。小表每组取两种，视频表另加 FrameFusion [11]。

图像任务是 GQA、POPE、MME、MMBench、ScienceQA-IMG、TextVQA-OCR，以及待补的 AI2D 和 VizWiz [9, 13, 15, 16, 20, 26, 27, 30]。POPE 报告 F1，MME 在主表和本轮六项里用感知分，分母 1510.70。其余分母为 GQA 61.90、POPE 85.80、MMBench 64.10、ScienceQA-IMG 69.51、TextVQA-OCR 58.20。相对分数是 100× 绝对分 / 分母，Rel.6 与 Rel.8 是对应任务上这些比值的算术平均。样本数为 GQA 12578、POPE 9000、MME 2374、MMBench 4329、ScienceQA-IMG 2017、TextVQA-OCR 5000。双深度对照使用更早的四项协议，MME 为感知加认知，分母 1852，不能与感知分列混用。

评测在 NVIDIA V100 上用 lmms-eval 按单样本进行 [37]。问题、选项和 OCR 提示按各任务协议进入语言模型。问题交换的方向只从问题句的内容词计算。层均容量 $\bar{K} = W/L$ 用来对齐一次剪枝和分层剪枝。主表三档是 $\bar{K} = 128$、64、32，相对 576 个原始位置的 token-layer 预算分别减少 77.8%、88.9% 和 94.4%。短横线表示该格还没有同协议记录。

4.2. LLaVA-1.5-7B

表 1 里，94.4% 这一档的 BELA 得到 GQA 57.08、POPE F1 86.19、MME 感知分 1408.92、MMBench 61.51、ScienceQA-IMG 69.86、TextVQA-OCR 53.28，Rel.6 为 95.66%。ScienceQA 与 POPE 接近或超过各自参考，GQA 和 TextVQA 仍明显低于完整模型。外部方法和另外两档没有填入文献表里的数字：那些数字来自不同的保留定义、任务集合和 Dense 分母，不能与 $\bar{K}$ 直接并排。

4.3. 高分辨率迁移

LLaVA-NeXT 的切块和 Qwen2.5-VL 的动态分辨率会改变视觉序列长度，转移结果要用各模型自己的 Dense。

Table 1. LLaVA-1.5-7B 八任务主结果。分组与三档预算沿用 SCoRe 的表式。MME 为感知分。Rel.6 只平均已有六项，Rel.8 在 AI2D 与 VizWiz 齐备后计算。短横线待填。

方法	GQA	POPE	MME	MMB	SQA	Text	AI2D	Viz	Rel.6	Rel.8
完整模型，576 个视觉位置										
LLaVA-1.5-7B	61.90	85.80	1510.70	64.10	69.51	58.20	–	–	100.00	–
K=128，预算减少 77.8%										
交互注意力										
FastV [5]	–	–	–	–	–	–	–	–	–	–
SparseVLM [40]	–	–	–	–	–	–	–	–	–	–
ViTCoP [28]	–	–	–	–	–	–	–	–	–	–
视觉代表										
DART [32]	–	–	–	–	–	–	–	–	–	–
DivPrune [2]	–	–	–	–	–	–	–	–	–	–
SCoRe [35]	–	–	–	–	–	–	–	–	–	–
联合选择										
VisionZip [36]	–	–	–	–	–	–	–	–	–	–
CoIn [7]	–	–	–	–	–	–	–	–	–	–
PruneSID [8]	–	–	–	–	–	–	–	–	–	–
BELA	–	–	–	–	–	–	–	–	–	–
K=64，预算减少 88.9%										
交互注意力										
FastV [5]	–	–	–	–	–	–	–	–	–	–
SparseVLM [40]	–	–	–	–	–	–	–	–	–	–
ViTCoP [28]	–	–	–	–	–	–	–	–	–	–
视觉代表										
DART [32]	–	–	–	–	–	–	–	–	–	–
DivPrune [2]	–	–	–	–	–	–	–	–	–	–
SCoRe [35]	–	–	–	–	–	–	–	–	–	–
联合选择										
VisionZip [36]	–	–	–	–	–	–	–	–	–	–
CoIn [7]	–	–	–	–	–	–	–	–	–	–
PruneSID [8]	–	–	–	–	–	–	–	–	–	–
BELA	–	–	–	–	–	–	–	–	–	–
K=32，预算减少 94.4%										
交互注意力										
FastV [5]	–	–	–	–	–	–	–	–	–	–
SparseVLM [40]	–	–	–	–	–	–	–	–	–	–
ViTCoP [28]	–	–	–	–	–	–	–	–	–	–
视觉代表										
DART [32]	–	–	–	–	–	–	–	–	–	–
DivPrune [2]	–	–	–	–	–	–	–	–	–	–
SCoRe [35]	–	–	–	–	–	–	–	–	–	–
联合选择										
VisionZip [36]	–	–	–	–	–	–	–	–	–	–
CoIn [7]	–	–	–	–	–	–	–	–	–	–
PruneSID [8]	–	–	–	–	–	–	–	–	–	–
BELA	57.08	86.19	1408.92	61.51	69.86	53.28	–	–	95.66	–

Table 2. LLaVA-NeXT-7B。六项经典任务，容量与分数待填。

方法	Signal	GQA	POPE	MME	MMB	SQA	Text
Dense	Full	–	–	–	–	–	–
FastV [5]	Attn.	–	–	–	–	–	–
SparseVLM [40]	Attn.	–	–	–	–	–	–
DivPrune [2]	Geom.	–	–	–	–	–	–
SCoRe [35]	Sal.+Cov.	–	–	–	–	–	–
CoIn [7]	Hybrid	–	–	–	–	–	–
PruneSID [8]	Hybrid	–	–	–	–	–	–
BELA	Stage	–	–	–	–	–	–

Table 3. Qwen2.5-VL-7B。上块减少 80.2% 的视觉预算，下块减少 90.1%。分数待填。

方法	Signal	GQA	POPE	MME	MMB	SQA	Text
压缩 80.2%							
Dense	Full	–	–	–	–	–	–
FastV [5]	Attn.	–	–	–	–	–	–
SparseVLM [40]	Attn.	–	–	–	–	–	–
DivPrune [2]	Geom.	–	–	–	–	–	–
SCoRe [35]	Sal.+Cov.	–	–	–	–	–	–
CoIn [7]	Hybrid	–	–	–	–	–	–
PruneSID [8]	Hybrid	–	–	–	–	–	–
BELA	Stage	–	–	–	–	–	–
压缩 90.1%							
FastV [5]	Attn.	–	–	–	–	–	–
SparseVLM [40]	Attn.	–	–	–	–	–	–
DivPrune [2]	Geom.	–	–	–	–	–	–
SCoRe [35]	Sal.+Cov.	–	–	–	–	–	–
CoIn [7]	Hybrid	–	–	–	–	–	–
PruneSID [8]	Hybrid	–	–	–	–	–	–
BELA	Stage	–	–	–	–	–	–

表 2 和表 3 只保留六项经典任务。Signal 标的是方法的主要依据：Attn. 为交互注意力，Geom. 为特征几何，Sal.+Cov. 为显著性加覆盖，Hybrid 为联合准则，Stage 为入口构建后再分层执行。Qwen 的两档压缩率是 80.2% 和 90.1%。两张表的分数都还没有同协议记录。

Table 4. 视频理解。同骨干、同帧采样下比较。四列都待填。

方法	LongVB	V-MME	LVE	第四项
Dense	–	–	–	–
FastV [5]	–	–	–	–
SparseVLM [40]	–	–	–	–
DivPrune [2]	–	–	–	–
SCoRe [35]	–	–	–	–
CoIn [7]	–	–	–	–
PruneSID [8]	–	–	–	–
FrameFusion [11]	–	–	–	–
BELA	–	–	–	–

Table 5. 效率位置。同设备、同输入、固定生成长度。数字待测。

方法	TTFT	生成时间	峰值显存	加速比
Dense	–	–	–	1.00
SCoRe [35]	–	–	–	–
CoIn [7]	–	–	–	–
BELA，交换关	–	–	–	–
BELA	–	–	–	–

4.4. 视频理解

视频表预留四个基准：LongVideoBench、Video-MME、LVE，以及名称尚未确认的第四项 [10, 33]。LVE 的全称待核对后再补引用。比较对象包括表 4 中的图像方法，以及面向帧间重复的 FrameFusion。帧标记、时间标记和图像 patch 分开计数。这一节没有填入分数。

4.5. 效率

效率还没有测量。计划在同一张 V100 上，对 Dense、一种交互基线、一种覆盖基线、关闭问题交换的 BELA 和完整 BELA，使用相同图像、批量 1 和精度。准确率评测按任务自然停止。计时另用固定生成长度，避免答案长短混进延迟。端到端首 token 时间从已经载入的图像和文本算起，包含视觉塔、投影、选择和预填充，直到第一个生成 token 可用。同时记录这段生成的总时间和峰值显存。模块计时分开看视觉塔、全网格投影、双深度与配额、问题交换，以及剪点上的问题--键乘积。预热不计入稳态。每个配置重复数轮，报告中位数、均值和尾部。相同的 W 只说明视觉 token-layer 数量相同，加速比以这组计时为准。表 5 留待填入。

4.6. 消融

双深度对照来自更早的 W=2048 协议，问题交换关闭，MME 用总分，所以不能和表 1 的 95.66% 写成同一预算。中层在 GQA 和 POPE 上最高，深层在 MMBench 上最高，双深度加旧覆盖在 MME 和四项相对均值上最高，见表 6。GQA 上双深度低于只使用中层。MMBench 全量里，中层对、深层错、双深度对的有 35 题；深层对、中层错、双深度也错的有 38 题。双深度提供的是两套排序，不是每个任务上的更优深度。

覆盖变体固定双深度并关闭问题交换，使用本轮六项和感知分。只修正空格与负余弦时，Rel.6 从 93.47% 变为 93.50%。去掉空格候选的显著性后，POPE 降到 76.33，Rel.6 降到 90.96%。格子配额在这组里最高，为 93.89%，MME 感知分和 TextVQA 上升，POPE 与 MMBench 下降。逐步更新原型是 93.77%，把残差放宽到锚点之外是 93.27%。完整六行见附录。

Table 6. 双深度。问题交换关闭，MME-T 为总分，Rel.4 只用这四项。

引导	GQA	POPE	MME-T	MMB	Rel.4
中层	57.84	83.97	1718.0	61.94	95.18
深层	56.34	81.28	1745.7	62.97	94.56
双深度	57.33	82.77	1744.5	62.54	95.22
双深度 + 旧覆盖	57.18	82.99	1765.2	62.20	95.36

在格子配额上打开问题交换，最小一档把 Rel.6 从 93.89% 提高到 95.66%。旧覆盖加同一档交换是 95.29%，低于这一组合。GQA 从 55.92 到 57.08：由错到对 498 题，由对到错 353 题，净增 145 题。POPE F1 从 81.48 到 86.19，TextVQA 从 53.85 到 53.28。再增大交换上限，POPE 继续上升，MME、MMBench、ScienceQA 和 TextVQA 一起下降，Rel.6 依次为 94.78%、93.68% 和 93.02%。最小一档是这四档里的六项最高值，上限本身是任务取舍，不是越大越好。

同一个 W=1024 下，第一次收缩较晚的 Rel.6 为 93.47%，两次较早收缩为 87.67% 和 87.45%。晚收缩那一档的入口个数更小，分数反而更高。这三档同时改变了入口容量和各档维持的层数，不能单独画成“入口越小越差”。历史中间档在另一套四项协议上，中间过少为 92.76%，中间适中为 95.36%，中间很多但很快掉到最终档为 94.56%；维持层数和中间个数也绑在一起。前两档相同、只改最后两档时，Rel.6 为 96.78% 和 96.89%，相差 0.11 个百分点。深层已经走过之后，所比较的末段分配对均值影响很小。具体保留序列和层数写在附录，不写入方法定义。

图 3 用半栏放进同一次前向的四联保留图。问题是瓶身饮料品牌，标准答案为 Perrier。问题交换把一部分亮块从水管移到商标附近。钟楼与无手套两例用同样的半栏尺寸放在附录：钟楼金标为 B，两种入口都答 B；无手套一例两边都答 No，只说明亮块从救生圈文字移到下方人物，图中没有手套。旧的按数据集行号叠上去的图没有使用，因为当时的轨迹按问题长度排序，格子和图像不是同一次前向。

5. 结论

本文将视觉 token 剪枝写成给定分层计算预算下、覆盖保真约束的查询自适应子集选择。基底先由双深度描述和格子配额固定，问题交换只在容量、覆盖失真和修改距离内改变入口，分层日程再决定这些索引参与哪些层。局部规则给出覆盖包络，不求解全局最优，也不把某一组保留个数写成方法的一部分。

在 LLaVA-1.5-7B 已完成的 94.4% 预算上，六项相对平均为 95.66%。交换提高了 GQA 和 POPE，同时降低了 TextVQA。浅层过早收缩的损失大于所比较的末段微调。单层显著性不能代替另一深度的排序，纯视觉覆盖也不读取当前问题。AI2D、VizWiz、77.8% 与 88.9% 两档、LLaVA-NeXT、Qwen2.5-VL 的 80.2% 和 90.1%、四项视频基准，以及 TTFT、生成时间和显存，都还留

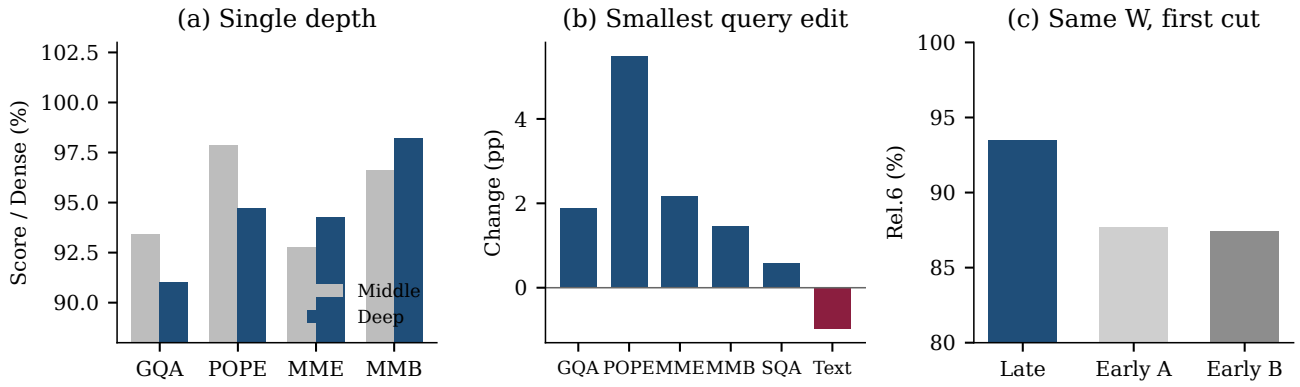


Figure 2. 三组已经分开的观察。(a) 关闭问题交换时，中层与深层的四项相对分各有高低，MME 用总分。(b) 格子配额基底上，最小一档交换的相对分变化；TextVQA 为负。(c) 同一个 W 下，第一次收缩较晚的 Rel.6 更高，MME 用感知分。三幅图的分母不完全相同。

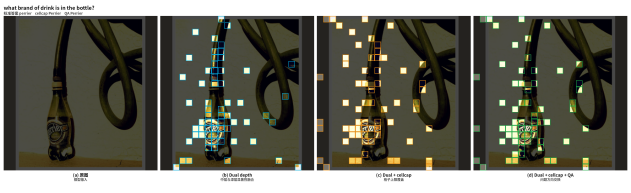


Figure 3. TextVQA：瓶身商标。未选区域压暗，选中 patch 保持原亮度。(b) (c) (d) 来自同一次前向。配额与日志逐格重合。格子配额和问题交换都回答 Perrier。

在表中待填。

LLM Usage Statement

本稿使用大语言模型协助中文初稿组织、相关工作表述、LaTeX 排版和公式与实验记录的对照。模型名称与版本由写作环境提供。实验数字只来自已归档的评测记录；未完成的单元格保持空白。作者核对了算法定义、引用和表格口径，并对正文中的科学结论负责。

References

[1] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katie Millican, Malcolm Reynolds, Roman Ring, Eliza Rutherford, Serkan Cabi, Tengda Han, Zhitao Gong, Sina Samangooei, Marianne Monteiro, Jacob Menick, Sebastian Borgeaud, Andrew Brock, Aida Nematzadeh, Sahand Sharifzadeh, Mikolaj Binkowski, Ricardo Barreira, Oriol Vinyals, Andrew Zisserman, and Karen Simonyan. Flamingo: a Visual Language Model for Few-Shot Learning. In *Advances in Neural Information Processing Systems*, 2022. 1

[2] Saeed Ranjbar Alvar, Gursimran Singh, Mohammad Akbari, and Yong Zhang. DivPrune: Diversity-based Visual Token Pruning for Large Multimodal Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9392–9401, 2025. 1, 2, 3, 4, 5

[3] Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibo Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, Humen Zhong, Yuanzhi Zhu, Mingkun Yang, Zhaohai Li, Jianqiang Wan, Pengfei Wang, Wei Ding, Zheren Fu, Yiheng Xu, Jiabo Ye, Xi Zhang, Tianbao Xie, Zesen Cheng, Hang Zhang, Zhibo Yang, Haiyang Xu, and Junyang Lin. Qwen2.5-VL Technical Report. *arXiv preprint arXiv:2502.13923*, 2025. 1, 3

[4] Daniel Bolya, Cheng-Yang Fu, Xiaoliang Dai, Peizhao Zhang, Christoph Feichtenhofer, and Judy Hoffman. Token Merging: Your ViT But Faster. In *International Conference on Learning Representations*, 2023. 2

[5] Liang Chen, Haozhe Zhao, Tianyu Liu, Shuai Bai, Junyang Lin, Chang Zhou, and Baobao Chang. An Image is Worth 1/2 Tokens After Layer 2: Plug-and-Play Inference Acceleration for Large Vision-Language Models. In *Computer Vision - ECCV 2024*, 2024. 1, 2, 3, 4, 5

[6] Sixun Dong, Juhua Hu, Mian Zhang, Ming Yin, Yanjie Fu, and Qi Qian. MMTok: Multimodal Coverage Maximization for Efficient Inference of VLMs. In *International Conference on Learning Representations*, 2026. 2

[7] Chenxi Du, Yongheng Deng, Jiani Liu, Yujia Zhang, Xi Chen, and Ju Ren. CoIn: Coverage and Informativeness-Guided Token Reduction for Efficient Large Multimodal Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10492–10501, 2026. 1, 2, 3, 4, 5

[8] Zhengyao Fang, Pengyuan Lyu, Chengquan Zhang, Guangming Lu, Jun Yu, and Wenjie Pei. Prune Redundancy, Preserve Essence: Vision Token Compression in VLMs via Synergistic Importance-Diversity. In *International Conference on Learning Representations*, 2026. 1, 2, 3, 4, 5

[9] Chaoyou Fu, Peixian Chen, Yunhang Shen, Yulei Qin, Mengdan Zhang, Xu Lin, Jinrui Yang, Xiawu Zheng, Ke Li, Xing Sun, Yunsheng Wu, Rongrong Ji, Caifeng Shan, and Ran He. MME: A Comprehensive Evaluation Benchmark

for Multimodal Large Language Models. *arXiv preprint arXiv:2306.13394*, 2023. 3

[10] Chaoyou Fu, Yuhan Dai, Yongdong Luo, Lei Li, Shuhuai Ren, Renrui Zhang, Zihan Wang, Chenyu Zhou, Yunhang Shen, Mengdan Zhang, et al. Video-MME: The First-Ever Comprehensive Evaluation Benchmark of Multi-modal LLMs in Video Analysis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025. 5

[11] Tianyu Fu, Tengxuan Liu, Qinghao Han, Guohao Dai, Shengen Yan, Huazhong Yang, Xuefei Ning, and Yu Wang. FrameFusion: Combining Similarity and Importance for Video Token Reduction on Large Vision Language Models. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 22654–22663, 2025. 2, 3, 5

[12] Yichen Guo, Tinghao Wang, Qizhe Zhang, Lingbei Meng, Yuan Zhang, Jiajun Cao, Hao Jiang, Chenwei Wu, Jixian Wu, Sixiang Chen, Tao Luo, Hongyang Cheng, Kai Tang, Chenxi Li, Renyuan Li, Xiande Huang, Wenya Wang, and Shanghang Zhang. STAR-Pro: Stage-Wise Token Adaptive Reduction with Progressive Refinement for Efficient Large Vision-Language Models. *arXiv preprint arXiv:2609.05916*, 2026. 2

[13] Danna Gurari, Qing Li, Abigale J. Stangl, Anhong Guo, Chi Lin, Kristen Grauman, Jiebo Luo, and Jeffrey P. Bigham. VizWiz Grand Challenge: Answering Visual Questions from Blind People. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2018. 3

[14] Shengli He, Yongchao Liang, Roumeng He, Junjie Zeng, Jiyuan He, Can Wu, and Li Zheng. QCPruner: Query-Conditioned Population Coverage for Visual Token Pruning. *arXiv preprint arXiv:2609.19990*, 2026. 2

[15] Drew A. Hudson and Christopher D. Manning. GQA: A New Dataset for Real-World Visual Reasoning and Compositional Question Answering. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019. 3

[16] Aniruddha Kembhavi, Mike Salvato, Eric Kolve, Minjoon Seo, Hannaneh Hajishirzi, and Ali Farhadi. A Diagram is Worth a Dozen Images. In *European Conference on Computer Vision*, 2016. 3

[17] Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph E. Gonzalez, Hao Zhang, and Ion Stoica. Efficient Memory Management for Large Language Model Serving with PagedAttention. In *Proceedings of the 29th Symposium on Operating Systems Principles*, 2023. 1

[18] Bo Li, Yuanhan Zhang, Dong Guo, Renrui Zhang, Feng Li, Hao Zhang, Kaichen Zhang, Peiyuan Zhang, Yanwei Li, Ziwei Liu, and Chunyuan Li. LLaVA-OneVision: Easy Visual Task Transfer. *arXiv preprint arXiv:2408.03326*, 2024. 1, 3

[19] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models. In *Proceedings of the 40th International Conference on Machine Learning*, pages 19730–19742, 2023. 1

[20] Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. Evaluating Object Hallucination in Large Vision-Language Models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, 2023. 3

[21] Hui Lin and Jeff Bilmes. A Class of Submodular Functions for Document Summarization. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies*, pages 510–520, 2011. 2

[22] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual Instruction Tuning. In *Advances in Neural Information Processing Systems*, 2023. 1

[23] Haotian Liu, Chunyuan Li, Yuheng Li, and Yong Jae Lee. Improved Baselines with Visual Instruction Tuning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 26296–26306, 2024. 3

[24] Haotian Liu, Chunyuan Li, Yuheng Li, Bo Li, Yuanhan Zhang, Sheng Shen, and Yong Jae Lee. LLaVA-NeXT: Improved reasoning, OCR, and world knowledge. https://llava-vl.github.io/blog/2024-01-30-llava-next/, 2024. 1, 3

[25] Jizhihui Liu, Guangdao Zhu, Feiyi Du, Niu Lian, Jun Li, Bin Chen, Weili Guan, and Yaowei Wang. HiPrune: Hierarchical Attention for Efficient Token Pruning in Vision-Language Models. In *Findings of the Association for Computational Linguistics: ACL 2026*, pages 3274–3291, 2026. 2

[26] Yuan Liu, Haodong Duan, Yuanhan Zhang, Bo Li, Songyang Zhang, Wangbo Zhao, Yike Yuan, Jiaqi Wang, Conghui He, Ziwei Liu, Kai Chen, and Dahua Lin. MMBench: Is Your Multi-modal Model an All-around Player? In *Computer Vision – ECCV 2024*, 2024. 3

[27] Pan Lu, Swaroop Mishra, Tony Xia, Liang Qiu, Kai-Wei Chang, Song-Chun Zhu, Oyvind Tafjord, Peter Clark, and Ashwin Kalyan. Learn to Explain: Multimodal Reasoning via Thought Chains for Science Question Answering. In *Advances in Neural Information Processing Systems*, 2022. 3

[28] Wen Luo, Peng Chen, Xiaotao Huang, and LiQun Huang. ViTCoP: Accelerating Large Vision-Language Models via Visual and Textual Semantic Collaborative Pruning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2026. 1, 2, 3, 4

[29] Yuzhang Shang, Mu Cai, Bingxin Xu, Yong Jae Lee, and Yan Yan. LLaVA-PruMerge: Adaptive Token Reduction for Efficient Large Multimodal Models. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 22857–22867, 2025. 2

[30] Amanpreet Singh, Vivek Natarajan, Meet Shah, Yu Jiang, Xinlei Chen, Dhruv Batra, Devi Parikh, and Marcus Rohrbach. Towards VQA Models That Can Read. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019. 3

[31] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention Is All You Need. In *Advances in Neural Information Processing Systems*, 2017. 1

[32] Zichen Wen, Yifeng Gao, Shaobo Wang, Junyuan Zhang, Qintong Zhang, Weijia Li, Conghui He, and Linfeng Zhang. Stop Looking for "Important Tokens" in Multimodal Language Models: Duplication Matters More. In *Proceedings of*

the 2025 Conference on Empirical Methods in Natural Language Processing, 2025. 1, 2, 3, 4

[33] Haoning Wu, Dongxu Li, Bei Chen, and Junnan Li. LongVideoBench: A Benchmark for Long-context Interleaved Video-Language Understanding. In *Advances in Neural Information Processing Systems*, 2024. 5

[34] Long Xing, Qidong Huang, Xiaoyi Dong, Jiajie Lu, Pan Zhang, Yuhang Zang, Yuhang Cao, Conghui He, Jiaqi Wang, Feng Wu, and Dahua Lin. Conical Visual Concentration for Efficient Large Vision-Language Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14593–14603, 2025. 1, 2

[35] Tong Xu, Hailong Shi, and Xingyu Gao. SCoRe: Salience-Coverage Reduction for Vision Token Pruning in Vision-Language Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 24686–24695, 2026. 1, 2, 3, 4, 5

[36] Senqiao Yang, Yukang Chen, Zhuotao Tian, Chengyao Wang, Jingyao Li, Bei Yu, and Jiaya Jia. VisionZip: Longer is Better but Not Necessary in Vision Language Models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 19792–19802, 2025. 1, 2, 3, 4

[37] Kaichen Zhang, Bo Li, Peiyuan Zhang, Fanyi Pu, Joshua Adrian Cahyono, Kairui Hu, Shuai Liu, Yuanhan Zhang, Jingkang Yang, Chunyuan Li, and Ziwei Liu. LMMs-Eval: Reality check on the evaluation of large multimodal models. In *Findings of the Association for Computational Linguistics: NAACL*, 2025. 3

[38] Qizhe Zhang, Aosong Cheng, Ming Lu, Renrui Zhang, Zhiyong Zhuo, Jiajun Cao, Shaobo Guo, Qi She, and Shanghang Zhang. Beyond Text-Visual Attention: Exploiting Visual Cues for Effective Token Pruning in VLMs. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 20857–20867, 2025. 2

[39] Qizhe Zhang, Mengzhen Liu, Lichen Li, Ming Lu, Yuan Zhang, Junwen Pan, Qi She, and Shanghang Zhang. Beyond Attention or Similarity: Maximizing Conditional Diversity for Token Pruning in MLLMs. In *Advances in Neural Information Processing Systems*, 2025. 2

[40] Yuan Zhang, Chun-Kai Fan, Junpeng Ma, Wenzhao Zheng, Tao Huang, Kuan Cheng, Denis A Gudovskiy, Tomoyuki Okuno, Yohei Nakata, Kurt Keutzer, and Shanghang Zhang. SparseVLM: Visual Token Sparsification for Efficient Vision-Language Model Inference. In *Proceedings of the 42nd International Conference on Machine Learning*, pages 74840–74857, 2025. 1, 2, 3, 4, 5

A. 其余记录

表 7 和表 8 补上正文消融的六项绝对分。覆盖变体关闭问题交换。交换上限加在格子配额上，四档按记录中的递增顺序排列，正文不把具体次数写入方法。

同一个 $W{=}1024$ 的三次首次收缩，保留序列与维持层数是 $(64, 17, 10)$ 对 $(12, 8, 12)$、$(128, 24, 16)$ 对 $(4, 8, 20)$、$(160, 28, 8)$ 对 $(4, 8, 20)$。三者同时改变入口和各档长度。历史中间档的四项绝对分是：中间 61 且维持很长，GQA 56.10、POPE 78.11、MME 总分 1720.1、MMBench 61.86；中间 90，57.18、82.99、1765.2、62.20；中间 148 但很快进入最终档，56.60、83.38、1781.6、59.88。末段“32 然后 12”与“24 然后 16”的六项均值是 96.78% 与 96.89%，MME 用感知分。

Table 7. 覆盖补选的六项对照。MME 为感知分。

策略	GQA	POPE	MME	MMB	SQA	Text	Rel.6
旧覆盖	55.57	82.21	1339.28	61.34	68.91	53.41	93.47
修空格与负余弦	55.96	81.50	1349.46	61.17	68.86	53.41	93.50
空格去掉显著性	54.15	76.33	1298.96	59.45	69.26	52.93	90.96
逐步更新原型	55.70	82.12	1371.95	60.14	69.51	53.73	93.77
格子配额	55.92	81.48	1376.34	60.57	69.46	53.85	93.89
残差放到锚点外	55.40	81.07	1363.77	60.14	68.86	53.82	93.27

Table 8. 格子配额上的四档交换。MME 为感知分。

上限	GQA	POPE	MME	MMB	SQA	Text	Rel.6
关	55.92	81.48	1376.34	60.57	69.46	53.85	93.89
最小一档	57.08	86.19	1408.92	61.51	69.86	53.28	95.66
第二档	57.04	87.08	1395.42	60.65	68.62	52.00	94.78
第三档	56.57	87.03	1356.98	59.79	67.82	51.54	93.68
第四档	56.60	87.29	1327.41	58.85	67.67	51.16	93.02

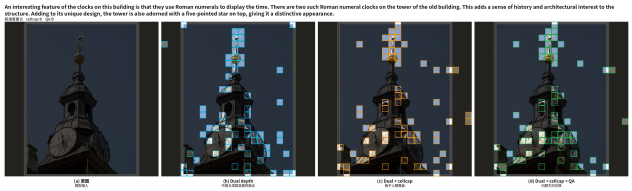


Figure 4. MMBench 钟楼。金标为 B，格子配额和问题交换都答 B。配额比双深度多亮出外围格子，交换再把一部分亮块收回钟面。

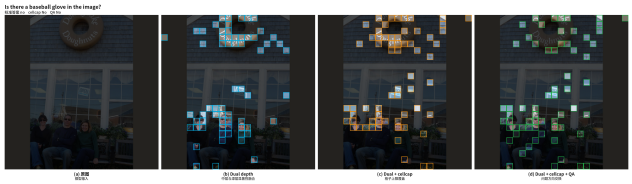


Figure 5. POPE：图中是否有棒球手套。金标为 No，两种入口都答 No。交换把一部分亮块从救生圈上的文字移到下方人物。此例只说明位置变化。

式 (10) 的截断区间和分母里的常数 2 是产生当前分数的实现，换模型时不自动沿用。关系词从查询方向中去掉，仍留在语言模型输入里。标准差过小或内容词为空时不交换。候选池大小、λ_r、λ_c、γ、η、ε 和 τ 的初值同样属于配置。效率测量建议先固定约 200 个图像问题，预热 20 次，再至少重复三轮；GPU 计时在边界同步，报告中位数、均值和 P90。固定长度计时统一生成 32 个 token，并与自然停止的准确率分开保存。